

Cyrus CS231A 导学讲义

Computer Vision, 3D Reconstruction, SLAM, Spatial Intelligence

基于 Stanford CS231A course notes 的中文学习版整理

官方课程	Stanford CS231A
本地 PDF	public/courses/cs231a/course-notes/
学习方式	网页交互 + GoodNotes 推导 + Obsidian 思维图 + Notion 进度证据

Contents

使用方式	3
1 课程总地图	3
2 Camera Models	3
2.1 从针孔模型开始	3
2.2 从物理成像到像素坐标	3
2.3 完整相机投影	4
2.4 相机标定	4
2.5 刚体变换、畸变和弱透视	4
3 Single View Metrology	5
3.1 四类 2D 变换	5
3.2 直线、交点和无穷远点	5
3.3 消失点和消失线	5
3.4 用消失点估计角度和内参	5
4 Epipolar Geometry	6
4.1 为什么需要两张图	6
4.2 Essential Matrix	6
4.3 Fundamental Matrix	6
4.4 八点法和归一化八点法	7
4.5 图像校正	7
5 Stereo Systems and Structure from Motion	7
5.1 三角测量	7
5.2 非线性精修	8
5.3 Affine Structure from Motion	8
5.4 重建歧义	8
5.5 Perspective SfM 与 Bundle Adjustment	8
6 Active and Volumetric Stereo	9
6.1 主动双目	9
6.2 体素重建	9
7 Fitting and Matching	9
7.1 普通最小二乘	9
7.2 Total Least Squares	10

7.3 鲁棒代价与 RANSAC	10
7.4 Hough Transform	10
8 Representations and Representation Learning	10
8.1 状态、Markov 性和观测	10
8.2 生成式与判别式	11
8.3 什么是好的表示	11
8.4 自编码器和自监督	11
9 Monocular Depth Estimation and Feature Tracking	11
9.1 深度与视差	11
9.2 监督、无监督和自监督深度	11
9.3 Feature Tracking 和 Dense Descriptors	12
10 Optical and Scene Flow	12
10.1 Optical Flow 与 Motion Field	12
10.2 光流约束方程	13
10.3 孔径问题与 Lucas-Kanade	13
11 Optimal Estimation	13
11.1 状态估计目标	13
11.2 Bayes Filter	14
11.3 Kalman Filter	14
11.4 Extended Kalman Filter	14
12 SLAM 与三维重建学习路线	15
公式速查	15
GoodNotes 页码建议	16

使用方式

这份 PDF 不是每日计划，而是自学时随时打开的路线图。每一章对应一份 CS231A course note。你在 iPad Pro 的 GoodNotes 里做两件事：

1. 抄核心公式，不要求马上全会，但要知道每个符号代表什么。
2. 画一张几何直觉图，例如相机、射线、平面、点云、体素、状态估计链。

Notion 负责记录证据：当前章节、GoodNotes 页码、掌握程度、仍不懂的问题。Obsidian 负责把概念连成图：camera model $\rightarrow$ epipolar geometry $\rightarrow$ triangulation $\rightarrow$ SfM $\rightarrow$ SLAM/state estimation。

1 课程总地图

编号	讲义	学习目标
1	Camera Models	从 3D 点到 2D 像素，建立相机内参、外参和标定基础。
2	Single View Metrology	用单张图里的消失点、消失线推回 3D 方向和相机信息。
3	Epipolar Geometry	两张图之间的点线约束： E 、 F 、八点法和校正。
4	Stereo Systems and SfM	三角测量、重投影误差、SfM、歧义和 Bundle Adjustment。
5	Active and Volumetric Stereo	主动双目、体素重建、space carving、voxel coloring。
6	Fitting and Matching	最小二乘、鲁棒拟合、RANSAC、Hough voting。
7	Representation Learning	状态、表示学习、生成式/判别式、自监督表示。
8	Monocular Depth and Tracking	单目深度、光度重建损失、特征跟踪、dense descriptors。
9	Optical and Scene Flow	光流约束、孔径问题、Lucas-Kanade、scene flow 入口。
10	Optimal Estimation	Bayes filter、Kalman filter、EKF，连接 SLAM 后端。

2 Camera Models

2.1 从针孔模型开始

相机模型的第一件事是把 3D 点投到 2D 平面。若 3D 点为 (x, y, z) ，焦距为 f ，针孔投影为

$$x' = f \frac{x}{z}, \quad y' = f \frac{y}{z}.$$

核心直觉：深度 z 在分母里，所以物体越远，投影越小。单个像素并不能唯一确定 3D 点，它只确定一条从相机中心出发的射线。

2.2 从物理成像到像素坐标

数字图像不是连续平面，而是像素网格。主点为 (c_x, c_y) ，像素尺度吸收到 α, β 后：

$$u = \alpha \frac{x}{z} + c_x, \quad v = \beta \frac{y}{z} + c_y.$$

相机内参矩阵为

$$\mathbf{K} = \begin{bmatrix} \alpha & 0 & c_x \\ 0 & \beta & c_y \\ 0 & 0 & 1 \end{bmatrix}.$$

若考虑 skew, 可写成

$$\mathbf{K} = \begin{bmatrix} \alpha & -\alpha \cot \theta & c_x \\ 0 & \beta / \sin \theta & c_y \\ 0 & 0 & 1 \end{bmatrix}.$$

2.3 完整相机投影

外参描述世界坐标到相机坐标:

$$P_c = RP_w + T.$$

完整投影写成

$$s \begin{bmatrix} u \\ v \\ 1 \end{bmatrix} = \mathbf{K} [R \quad T] \begin{bmatrix} X_w \\ Y_w \\ Z_w \\ 1 \end{bmatrix}.$$

一句话记忆: 外参管相机在哪里, 内参管相机怎么成像。

2.4 相机标定

已知一组 3D 标定点 P_i 和图像点 p_i , 要求相机矩阵 $\mathbf{M}$:

$$p_i \sim \mathbf{M}P_i.$$

令 $\mathbf{M}$ 的三行分别为 m_1, m_2, m_3 , 则

$$u_i = \frac{m_1 P_i}{m_3 P_i}, \quad v_i = \frac{m_2 P_i}{m_3 P_i}.$$

整理成线性约束:

$$u_i(m_3 P_i) - m_1 P_i = 0, \quad v_i(m_3 P_i) - m_2 P_i = 0.$$

因为 $\mathbf{M}$ 是 3×4 矩阵且整体尺度不重要, 所以有 11 个自由度; 每个对应点给 2 个方程, 至少需要 6 个 3D-2D 对应点。

2.5 刚体变换、畸变和弱透视

旋转矩阵满足

$$R^T R = I, \quad \det(R) = 1.$$

齐次坐标下的刚体变换为

$$\begin{bmatrix} v' \\ 1 \end{bmatrix} = \begin{bmatrix} R & t \\ 0 & 1 \end{bmatrix} \begin{bmatrix} v \\ 1 \end{bmatrix}.$$

弱透视假设物体深度变化相对平均深度很小:

$$x' \approx \frac{f}{z_0} x, \quad y' \approx \frac{f}{z_0} y.$$

GoodNotes 任务: 画出相机中心、图像平面、3D 点、投影点。标出 z 在分母里的位置。

3 Single View Metrology

3.1 四类 2D 变换

刚体变换保长度：

$$\begin{bmatrix} x' \\ y' \\ 1 \end{bmatrix} = \begin{bmatrix} R & t \\ 0 & 1 \end{bmatrix} \begin{bmatrix} x \\ y \\ 1 \end{bmatrix}.$$

相似变换保角度和长度比例：

$$\begin{bmatrix} x' \\ y' \\ 1 \end{bmatrix} = \begin{bmatrix} sR & t \\ 0 & 1 \end{bmatrix} \begin{bmatrix} x \\ y \\ 1 \end{bmatrix}.$$

仿射变换保直线和平行性：

$$T(v) = Av + t.$$

投影变换保直线，但不保平行性：

$$x' \sim Hx.$$

3.2 直线、交点和无穷远点

直线用齐次向量表示：

$$l = \begin{bmatrix} a \\ b \\ c \end{bmatrix}, \quad l^T \begin{bmatrix} x \\ y \\ 1 \end{bmatrix} = 0.$$

两条线的交点：

$$x = l \times l'.$$

平行线在齐次坐标里会交于无穷远点，其第三个坐标为 0。

3.3 消失点和消失线

若 3D 中一组平行线的方向为 d ，在图像中的消失点为

$$v = \mathbf{K}d.$$

若知道 $\mathbf{K}$ ，可反推出方向：

$$d = \frac{\mathbf{K}^{-1}v}{\|\mathbf{K}^{-1}v\|}.$$

一个平面上的多组平行线会产生多个消失点，它们连成这个平面的消失线或地平线 ℓ_{horiz} 。平面法向量可由

$$n = \mathbf{K}^T \ell_{\text{horiz}}$$

估计。

3.4 用消失点估计角度和内参

两组 3D 方向 d_1, d_2 的夹角满足

$$\cos \theta = \frac{d_1 \cdot d_2}{\|d_1\| \|d_2\|} = \frac{v_1^T \omega v_2}{\sqrt{v_1^T \omega v_1} \sqrt{v_2^T \omega v_2}}, \quad \omega = (\mathbf{K}\mathbf{K}^T)^{-1}.$$

若两组方向真实垂直：

$$v_1^T \omega v_2 = 0.$$

房间、走廊、建筑非常适合单视图测量，因为它们包含大量平行和垂直结构。

GoodNotes 任务：画三组互相垂直的边线，分别求三个消失点，再写下 $v_i^T \omega v_j = 0$ 。

4 Epipolar Geometry

4.1 为什么需要两张图

单张图的像素点只确定一条 3D 射线。第二张图加入后，第一张图中点 $\mathbf{p}$ 的对应点 $\mathbf{p}'$ 不再需要在整张图里搜索，而只需落在第二张图的一条对极线 ℓ' 上。

两个相机中心 O_1, O_2 和 3D 点 P 确定对极平面。该平面与两张图像平面的交线就是对极线。基本约束为

$$\mathbf{p}' \in \ell'.$$

4.2 Essential Matrix

在归一化相机坐标里，相机间相对运动为 R, T 。本质矩阵为

$$\mathbf{E} = [T_\times]R.$$

叉乘矩阵定义为

$$a \times b = [a_\times]b = \begin{bmatrix} 0 & -a_z & a_y \\ a_z & 0 & -a_x \\ -a_y & a_x & 0 \end{bmatrix} b.$$

对极约束：

$$\mathbf{p}^T \mathbf{E} \mathbf{p}' = 0.$$

$\mathbf{E}$ 包含两个相机之间的相对旋转和平移，秩为 2，有 5 个自由度。

4.3 Fundamental Matrix

真实图像通常是像素坐标，内参不能忽略。基础矩阵 $\mathbf{F}$ 直接约束像素坐标：

$$\mathbf{p}^T \mathbf{F} \mathbf{p}' = 0.$$

与 $\mathbf{E}$ 的关系为

$$\mathbf{F} = \mathbf{K}^{-T} \mathbf{E} \mathbf{K}'^{-1}, \quad \mathbf{E} = \mathbf{K}^T \mathbf{F} \mathbf{K}'.$$

对极线可由

$$\ell' = \mathbf{F}^T \mathbf{p}, \quad \ell = \mathbf{F} \mathbf{p}'$$

计算。

4.4 八点法和归一化八点法

每对匹配点 $\mathbf{p}_i = (u_i, v_i, 1)$ 与 $\mathbf{p}'_i = (u'_i, v'_i, 1)$ 给出

$$\mathbf{p}_i^T \mathbf{F} \mathbf{p}'_i = 0.$$

展开后形成

$$Wf = 0,$$

其中 f 是 $\mathbf{F}$ 拉平后的 9 维向量。 $\mathbf{F}$ 只差整体尺度，所以最少需要 8 对匹配点。实际先用 SVD 得到 $\mathbf{F}$ ，再强制

$$\text{rank}(\mathbf{F}) = 2, \quad \det(\mathbf{F}) = 0.$$

归一化八点法先做

$$q_i = T\mathbf{p}_i, \quad q'_i = T'\mathbf{p}'_i$$

来改善数值条件，再反归一化：

$$\mathbf{F} = T'^T \mathbf{F}_q T.$$

4.5 图像校正

图像校正寻找两个单应矩阵 H_1, H_2 ：

$$\tilde{\mathbf{p}} = H_1 \mathbf{p}, \quad \tilde{\mathbf{p}}' = H_2 \mathbf{p}'.$$

校正后，对应点在左右图中的纵坐标相同：

$$\tilde{v} = \tilde{v}'.$$

这把二维搜索变成一维搜索，是双目深度估计的关键。

5 Stereo Systems and Structure from Motion

5.1 三角测量

若两个相机都看到 3D 点 P ，它们的图像点为 $\mathbf{p}, \mathbf{p}'$ 。已知相机矩阵 $\mathbf{M}, \mathbf{M}'$ 时，理想情况下两条反投影射线相交于 P 。现实中有噪声，所以用重投影误差：

$$\min_{\hat{P}} \|\mathbf{M}\hat{P} - \mathbf{p}\|^2 + \|\mathbf{M}'\hat{P} - \mathbf{p}'\|^2.$$

线性三角测量可写为

$$AP = 0,$$

其中

$$A = \begin{bmatrix} xM_3 - M_1 \\ yM_3 - M_2 \\ x'M'_3 - M'_1 \\ y'M'_3 - M'_2 \end{bmatrix}.$$

5.2 非线性精修

投影要做齐次归一化，因此精修是非线性问题：

$$\min_{\hat{P}} \sum_i \|\mathbf{M}_i \hat{P} - \mathbf{p}_i\|^2.$$

Gauss–Newton 在当前估计附近线性化：

$$e(\hat{P} + \delta P) \approx e(\hat{P}) + J\delta P.$$

修正量为

$$\delta P = -(J^T J)^{-1} J^T e, \quad \hat{P} \leftarrow \hat{P} + \delta P.$$

5.3 Affine Structure from Motion

仿射或弱透视模型下：

$$x_{ij} = A_i X_j + b_i.$$

对每张图中心化：

$$\hat{x}_{ij} = x_{ij} - \bar{x}_i.$$

平移项消失：

$$\hat{x}_{ij} = A_i \hat{X}_j.$$

堆成测量矩阵：

$$D = MS,$$

其中 M 是 motion matrix， S 是 structure matrix。理想情况下

$$\text{rank}(D) = 3.$$

SVD 分解：

$$D \approx U_3 \Sigma_3 V_3^T.$$

Tomasi–Kanade 常用

$$M = U_3 \sqrt{\Sigma_3}, \quad S = \sqrt{\Sigma_3} V_3^T.$$

5.4 重建歧义

分解 $D = MS$ 不是唯一的，因为任意可逆矩阵 A 可插入：

$$D = MAA^{-1}S = (MA)(A^{-1}S).$$

仿射重建保平行关系，但长度、角度和尺度不一定真实。标定相机下，歧义通常缩小到 similarity ambiguity：整体旋转、平移和尺度。

5.5 Perspective SfM 与 Bundle Adjustment

从 $\mathbf{F}$ 可构造一组等价投影矩阵：

$$\tilde{M}_1 = [I \mid 0], \quad \tilde{M}_2 = [-[e_\times]\mathbf{F} \mid e],$$

其中 e 是极点，满足 $\mathbf{F}e = 0$ 。若相机已标定：

$$\mathbf{E} = \mathbf{K}^T \mathbf{F} \mathbf{K}, \quad \mathbf{E} = [t_\times] R.$$

从 $\mathbf{E}$ 分解 R, t 会有 4 组候选；正确解让最多三角化点同时位于两个相机前方。

Bundle Adjustment 同时优化相机和 3D 点：

$$\min_{\{M_i\}, \{X_j\}} \sum_{(i,j) \in \mathcal{V}} \|\pi(M_i X_j) - x_{ij}\|^2.$$

它是 SfM 和 SLAM 后端优化的核心思想。

6 Active and Volumetric Stereo

6.1 主动双目

传统双目最大难点是对应关系：

$$\mathbf{p} \leftrightarrow \mathbf{p}'.$$

主动双目把一台相机换成投影仪：

projector + camera.

投影仪发出已知点、线、彩色条纹或红外 pattern，相机观察到对应点后即可三角测量：

$$P = \text{triangulate}(p, p').$$

优点是降低匹配难度；代价是投影仪和相机都要标定，且受反光、透明、强光等影响。

6.2 体素重建

Volumetric Stereo 从 3D 空间假设开始：先定义工作体积 V ，划成 voxel grid，然后把每个 voxel 投影到多张图，检查一致性。

Space carving 使用 silhouette。每张 silhouette 反投影成 visual cone，物体在多个视觉锥交集中：

$$\text{visual hull} = \bigcap_i \text{visual cone}_i.$$

若一个 voxel 投影到任一视图的 silhouette 外，就删掉。

Shadow carving 增加自阴影检查，帮助处理 concavity。Voxel coloring 使用颜色一致性：

$$\text{color}(x_1) \approx \text{color}(x_2) \approx \dots \approx \text{color}(x_n).$$

它要求表面近似 Lambertian，即观察颜色不随视角大幅变化。

7 Fitting and Matching

7.1 普通最小二乘

拟合直线

$$y = mx + b$$

时，令

$$w = \begin{bmatrix} m \\ b \end{bmatrix}, \quad E = \|Y - Xw\|^2.$$

求导得到 normal equation：

$$X^T X w = X^T Y,$$

闭式解为

$$w = (X^T X)^{-1} X^T Y.$$

7.2 Total Least Squares

普通最小二乘只看 y 方向误差，不适合竖直线。使用一般直线：

$$ax + by + c = 0.$$

点到线距离：

$$d_i = \frac{|ax_i + by_i + c|}{\sqrt{a^2 + b^2}}.$$

加约束

$$a^2 + b^2 = 1$$

后，误差为

$$E = \sum_i (ax_i + by_i + c)^2.$$

最优直线经过数据中心 $(\bar{x}, \bar{y})$ ：

$$c = -a\bar{x} - b\bar{y}.$$

中心化后用 SVD 解，最小奇异值对应方向给出法向量。

7.3 鲁棒代价与 RANSAC

平方误差

$$C(u_i) = u_i^2$$

会让外点影响过大。鲁棒代价示例：

$$C(u_i, \sigma) = \frac{u_i^2}{\sigma^2 + u_i^2}.$$

RANSAC 反复随机采最小点集，拟合模型，统计 inliers：

$$P = \{x_i \mid r(x_i, w) < \delta\}.$$

估计基础矩阵时最小样本数为 $s = 8$ ；估计单应矩阵时 $s = 4$ 。迭代次数可估计为

$$n = \frac{\log(1 - p)}{\log(1 - (1 - \epsilon)^s)}.$$

7.4 Hough Transform

Hough voting 把图像点映射到参数空间。普通斜截式参数无界，常用极坐标直线：

$$x \cos \theta + y \sin \theta = \rho.$$

每个图像点在 (ρ, θ) 空间投票，峰值对应图像中的直线。

8 Representations and Representation Learning

8.1 状态、Markov 性和观测

状态 x_t 是系统当前足以预测未来的压缩描述。Markov 性：

$$P(x_{t+1} \mid x_t, x_{t-1}, \dots, x_1) = P(x_{t+1} \mid x_t).$$

若状态不可直接观测，引入观测 z_t ：

$$P(z_t \mid x_t, x_{t-1}, \dots) = P(z_t \mid x_t).$$

这就是 HMM、POMDP、SLAM 状态估计的基础。

8.2 生成式与判别式

生成式模型描述联合分布：

$$p(z, x) = p(z | x)p(x).$$

判别式模型直接描述

$$p(x | z).$$

视觉任务里，生成式方法像“给定姿态渲染图像再比较”，判别式方法像“神经网络从图像直接回归姿态”。

8.3 什么是好的表示

好的表示应该：

- compact: 压缩但不丢关键因素；
- explanatory: 足以解释输入变化；
- disentangled: 不同因素尽量独立；
- hierarchical: 低级特征组合成高级概念；
- useful: 让下游推理、预测、决策更容易。

8.4 自编码器和自监督

Autoencoder 学习瓶颈表示 z ：

$$\hat{X} = F(X), \quad L = \|X - \hat{X}\|.$$

自监督学习把输入的一部分当标签，例如用图像下半部分预测上半部分。空间智能中的世界模型也在做类似事情：学习一个能预测、压缩和支持决策的 latent state。

9 Monocular Depth Estimation and Feature Tracking

9.1 深度与视差

校正双目下，视差为

$$d = u_L - u_R.$$

深度公式：

$$Z = \frac{fb}{d},$$

其中 f 是焦距， b 是基线。近处视差大，远处视差小。

单目深度在几何上欠约束，但可以利用透视、尺度、遮挡、光照等统计线索学习。

9.2 监督、无监督和自监督深度

监督单目深度直接最小化预测深度与真值深度的误差。无监督双目深度把深度或视差作为中间表示，用右图重建左图：

$$\tilde{I}_l(u, v) = I_r(u - d_l(u, v), v).$$

典型损失含三部分：

$$C_s = \alpha_{ap}(C_{ap}^l + C_{ap}^r) + \alpha_{ds}(C_{ds}^l + C_{ds}^r) + \alpha_{lr}(C_{lr}^l + C_{lr}^r).$$

外观重建损失：

$$C_{ap}^l = \frac{1}{N} \sum_{i,j} \alpha \frac{1 - \text{SSIM}(I_{ij}^l, \tilde{I}_{ij}^l)}{2} + (1 - \alpha) \|I_{ij}^l - \tilde{I}_{ij}^l\|_1.$$

边缘感知平滑：

$$C_{ds}^l = \frac{1}{N} \sum_{i,j} |\partial_x d_{ij}^l| e^{-\|\partial_x I_{ij}^l\|} + |\partial_y d_{ij}^l| e^{-\|\partial_y I_{ij}^l\|}.$$

左右一致性：

$$C_{lr}^l = \frac{1}{N} \sum_{i,j} |d_{ij}^l - d_{i,j+d_{ij}^l}^r|.$$

自监督单目视频深度把深度和相邻帧位姿一起预测，通过 novel view synthesis 构造光度误差：

$$pe(I_a, I_b) = \frac{\alpha}{2} (1 - \text{SSIM}(I_a, I_b)) + (1 - \alpha) \|I_a - I_b\|_1,$$

$$L_p = \sum_{t'} pe(I_t, I_{t' \rightarrow t}).$$

9.3 Feature Tracking 和 Dense Descriptors

特征跟踪本质是跨帧对应关系问题。传统方法使用手工 keypoint 和 descriptor；现代方法学习每个像素的 dense descriptor：

$$f(I, u) \in \mathbb{R}^D.$$

匹配点希望 descriptor 距离小：

$$L_{\text{matches}} = \frac{1}{N_{\text{matches}}} \sum D(I_a, u_a, I_b, u_b)^2.$$

非匹配点希望距离大：

$$L_{\text{non-matches}} = \frac{1}{N_{\text{non-matches}}} \sum \max(0, M - D(I_a, u_a, I_b, u_b))^2.$$

总损失：

$$L = L_{\text{matches}} + L_{\text{non-matches}}.$$

10 Optical and Scene Flow

10.1 Optical Flow 与 Motion Field

Optical flow 是视频里每个像素的表现 2D 运动：

$$\mathbf{u} = \begin{bmatrix} u \\ v \end{bmatrix}.$$

Motion field 是 3D 运动向量投影到图像平面的理想速度场。二者不总相同：光照变化可能产生 optical flow，但真实 3D 点未动；无纹理旋转可能有 motion field 但没有可见 optical flow。

10.2 光流约束方程

亮度恒定假设:

$$I(x, y, t) = I(x + \Delta x, y + \Delta y, t + \Delta t).$$

小运动假设下, 一阶 Taylor 展开:

$$I(x + \Delta x, y + \Delta y, t + \Delta t) \approx I(x, y, t) + I_x \Delta x + I_y \Delta y + I_t \Delta t.$$

得到光流约束:

$$I_x u + I_y v + I_t = 0,$$

或

$$-I_t = \nabla I^T \mathbf{u}.$$

一个像素只有一个方程, 却有 u, v 两个未知数, 所以欠约束, 只能得到 normal flow。

10.3 孔径问题与 Lucas-Kanade

沿边缘方向的运动无法由局部窗口唯一确定, 这叫 aperture problem。Lucas-Kanade 假设邻域内像素共享同一个 flow:

$$A\mathbf{u} = b.$$

最小二乘解:

$$\mathbf{u}_{ls} = (A^T A)^{-1} A^T b.$$

可解性取决于

$$A^T A = \begin{bmatrix} \sum I_x^2 & \sum I_x I_y \\ \sum I_x I_y & \sum I_y^2 \end{bmatrix}.$$

纹理丰富、梯度方向多样的角点区域最适合跟踪。

11 Optimal Estimation

11.1 状态估计目标

状态估计要递归地估计

$$p(x_t \mid z_{1:t}, u_{1:t}),$$

也叫 belief:

$$bel(t).$$

Markov 转移模型:

$$p(x_t \mid x_{0:t-1}, z_{1:t-1}, u_{1:t}) = p(x_t \mid x_{t-1}, u_t).$$

测量模型:

$$p(z_t \mid x_{0:t}, z_{1:t-1}, u_{1:t}) = p(z_t \mid x_t).$$

11.2 Bayes Filter

Prediction:

$$\overline{bel}(x_t) = \int p(x_t | x_{t-1}, u_t) bel(x_{t-1}) dx_{t-1}.$$

Update:

$$bel(x_t) = \eta p(z_t | x_t) \overline{bel}(x_t),$$

其中 η 是归一化常数。

离散情形可以写成矩阵:

$$\widehat{bel}(t) = T(u_t) bel(t-1),$$

$$bel(t) = \frac{M(z_t) \widehat{bel}(t)}{\mathbf{1}^T M(z_t) \widehat{bel}(t)}.$$

11.3 Kalman Filter

线性高斯系统:

$$x_t = A_t x_{t-1} + B_t u_t + w_t, \quad z_t = C_t x_t + v_t.$$

噪声:

$$w_t \sim \mathcal{N}(0, Q_t), \quad v_t \sim \mathcal{N}(0, R_t).$$

预测均值和协方差:

$$\mu_{t|t-1} = A_t \mu_{t-1|t-1} + B_t u_t,$$

$$\Sigma_{t|t-1} = A_t \Sigma_{t-1|t-1} A_t^T + Q_t.$$

更新:

$$K_t = \Sigma_{t|t-1} C_t^T (C_t \Sigma_{t|t-1} C_t^T + R_t)^{-1},$$

$$\mu_{t|t} = \mu_{t|t-1} + K_t (z_t - C_t \mu_{t|t-1}),$$

$$\Sigma_{t|t} = \Sigma_{t|t-1} - K_t C_t \Sigma_{t|t-1}.$$

这里

$$z_t - C_t \mu_{t|t-1}$$

叫 innovation, 表示真实观测和预测观测的差。

11.4 Extended Kalman Filter

非线性系统:

$$x_t = f(x_{t-1}, u_t) + w_t, \quad z_t = g(x_t) + v_t.$$

EKF 在当前均值附近线性化:

$$A_t = \left. \frac{\partial f(x_t, u_t)}{\partial x_t} \right|_{x_t = \mu_{t-1|t-1}}, \quad C_t = \left. \frac{\partial g(x_t)}{\partial x_t} \right|_{x_t = \mu_{t|t-1}}.$$

然后使用 Kalman filter 的预测和更新形式。SLAM 中许多经典滤波器都可以看成这个框架的变体。

12 SLAM 与三维重建学习路线

1. 先会相机: $\mathbf{K}, [R | T]$, 知道像素如何来自 3D 点。
2. 再会两视图: $\mathbf{E}, \mathbf{F}$, 知道点如何约束对极线。
3. 再会深度: rectification、disparity、triangulation。
4. 再会鲁棒前端: matching、RANSAC、optical flow。
5. 再会后端: reprojection error、Gauss–Newton、Bundle Adjustment。
6. 最后接状态估计: Bayes filter、Kalman filter、EKF、factor graph。

你学习时不需要一天学完。每次只要完成一个闭环:

公式 $\rightarrow$ 几何图 $\rightarrow$ 一句话解释 $\rightarrow$ 一个失败模式。

公式速查

Pinhole:

$$x' = f \frac{x}{z},$$

$$y' = f \frac{y}{z}.$$

Camera projection:

$$s \begin{bmatrix} u \\ v \\ 1 \end{bmatrix} = \mathbf{K}[R | T] \begin{bmatrix} X \\ Y \\ Z \\ 1 \end{bmatrix}.$$

Vanishing point:

$$v = \mathbf{K}d,$$

$$d = \frac{\mathbf{K}^{-1}v}{\|\mathbf{K}^{-1}v\|}.$$

Epipolar:

$$\mathbf{p}^T \mathbf{E} \mathbf{p}' = 0,$$

$$\mathbf{p}^T \mathbf{F} \mathbf{p}' = 0.$$

Essential:

$$\mathbf{E} = [t_{\times}]R.$$

Fundamental:

$$\mathbf{F} = \mathbf{K}^{-T} \mathbf{E} \mathbf{K}'^{-1}.$$

Stereo depth:

$$Z = \frac{fb}{d}.$$

Triangulation:

$$AP = 0.$$

Bundle adjustment:

$$\min_{\{M_i\}, \{X_j\}} \sum_{(i,j) \in \mathcal{V}} \|\pi(M_i X_j) - x_{ij}\|^2.$$

RANSAC iterations:

$$n = \frac{\log(1-p)}{\log(1-(1-\epsilon)^s)}.$$

Optical flow:

$$I_x u + I_y v + I_t = 0.$$

Kalman gain:

$$K_t = \Sigma_{t|t-1} C_t^T (C_t \Sigma_{t|t-1} C_t^T + R_t)^{-1}.$$

GoodNotes 页码建议

页码	标题	必画图
001	Pinhole Camera	相机中心、图像平面、 z 深度。
002	Camera Matrix	$\mathbf{K}$ 、 R 、 T 、世界坐标到像素。
003	Vanishing Point	马路两侧线汇聚到消失点。
004	Epipolar Geometry	点 $\rightarrow$ 对极线。
005	Eight-Point and RANSAC	匹配点、内点、外点。
006	Triangulation	两条射线交出 3D 点。
007	SfM and BA	相机轨迹、稀疏点云、重投影误差。
008	Volumetric Stereo	voxel grid 和 visual hull。
009	Depth and Flow	视差、光流向量、孔径问题。
010	Bayes/Kalman/EKF	predict-update 状态估计链。