

Cyrus CS231n 导学讲义

Deep Learning for Computer Vision

按“李飞飞 CS231n / CS23DN”学习需求整理的中文路线版

官方课程	Stanford CS231n
官方 notes	cs231n.github.io
本地课程目录	docs/courses/cs231n/
学习方式	网页交互 + GoodNotes 推导 + Obsidian 概念图 + Notion 证据记录

本文是原创导学笔记和公式索引，不替代官方课程页面、slides、assignments 或 notes。

Contents

怎么用这份讲义	3
1 课程地图	3
2 Image Classification	3
2.1 数据驱动视觉	3
2.2 kNN	3
2.3 数据划分	4
3 Linear Classifiers	4
3.1 线性打分函数	4
3.2 Multiclass SVM Loss	4
3.3 Softmax and Cross Entropy	4
4 Optimization and Backpropagation	5
4.1 梯度下降	5
4.2 链式法则	5
4.3 反传的局部视角	5
5 Neural Networks	5
5.1 从线性到非线性	5
5.2 激活函数	6
5.3 初始化和正则化	6
6 Convolutional Neural Networks	6
6.1 卷积层	6
6.2 Pooling and Receptive Field	6
6.3 经典架构	6
7 Training Tricks and Transfer Learning	7
7.1 Batch Normalization	7
7.2 Dropout	7
7.3 Momentum and Adam	7
7.4 Transfer Learning	7
8 Detection and Segmentation	8
8.1 Detection	8
8.2 Segmentation	8

8.3 Dense Prediction	8
9 RNN, Attention, and Transformers	8
9.1 RNN	8
9.2 LSTM	8
9.3 Attention	9
10 Generative Models	9
10.1 Autoencoder	9
10.2 VAE	9
10.3 GAN	9
11 Self-supervised Vision	9
11.1 Contrastive Learning	9
11.2 Masked Modeling	10
11.3 Vision-Language Representation	10
12 CS231n 到空间智能的连接	10
公式速查	11
GoodNotes 页码建议	11

怎么用这份讲义

CS231A 解决“相机和几何如何恢复 3D”；CS231n 解决“神经网络如何从图像中学习表示”。你的空间智能路线需要二者合起来：

CS231A geometry + CS231n visual representation $\Rightarrow$ modern spatial intelligence.

每一章按四件事学习：

1. 概念：它解决什么视觉问题。
2. 公式：损失函数、梯度、层结构或概率目标。
3. GoodNotes：手抄核心公式并画一张结构图。
4. 网页/Notion：记录掌握度、错题、作业输出和下一步。

1 课程地图

编号	模块	学习目标
1	Image Classification	数据驱动分类、kNN、train/val/test。
2	Linear Classifiers	SVM、Softmax、正则化和概率解释。
3	Optimization and Backprop	SGD、链式法则、计算图反向传播。
4	Neural Networks	多层网络、激活函数、loss、初始化。
5	CNNs	卷积、池化、感受野、经典架构。
6	Training Tricks	BatchNorm、Dropout、优化器、迁移学习。
7	Dense Prediction	Detection、segmentation、IoU、NMS。
8	Sequence and Attention	RNN、LSTM、attention、Transformer。
9	Generative Models	Autoencoder、VAE、GAN、diffusion 入口。
10	Self-supervised Vision	Contrastive learning、CLIP/ViT 入口、空间智能连接。

2 Image Classification

2.1 数据驱动视觉

传统视觉会手工设计边缘、角点、纹理等特征；CS231n 的起点是数据驱动：给训练集

$$\{(x_i, y_i)\}_{i=1}^N,$$

学习一个函数

$$f_{\theta}(x) \rightarrow y.$$

图像分类的目标是把输入图像 x 映射到类别标签 y 。

2.2 kNN

kNN 不学习显式参数，只存训练样本。给新图像 x ，计算它和训练图像 x_i 的距离。常见距离：

$$d_1(x, x_i) = \sum_p |x_p - x_{i,p}|,$$

$$d_2(x, x_i) = \sqrt{\sum_p (x_p - x_{i,p})^2}.$$

选择最近的 k 个样本投票。它简单但测试慢，且像素距离并不等于语义相似。

2.3 数据划分

训练集用于拟合参数，验证集用于选超参数，测试集只做最后评估：

train $\rightarrow$ validation $\rightarrow$ test.

空间智能里同理：训练数据、验证场景、最终验收路线不能混用。

GoodNotes 任务：画出 train/val/test 三块数据，写下 L1、L2 距离，并解释为什么像素近不代表语义近。

3 Linear Classifiers

3.1 线性打分函数

线性分类器把图像拉平成向量 $x \in \mathbb{R}^D$ ，输出每类分数：

$$s = f(x; W, b) = Wx + b,$$

其中 $W \in \mathbb{R}^{C \times D}$ ， $b \in \mathbb{R}^C$ 。第 j 类分数为 s_j 。

3.2 Multiclass SVM Loss

若正确类别为 y_i ，SVM 希望正确类分数比其他类至少高 Δ ：

$$L_i = \sum_{j \neq y_i} \max(0, s_j - s_{y_i} + \Delta).$$

总损失加正则：

$$L = \frac{1}{N} \sum_i L_i + \lambda R(W), \quad R(W) = \sum_k W_k^2.$$

直觉：分类器不仅要答对，还要答得有 margin。

3.3 Softmax and Cross Entropy

Softmax 把分数转成概率：

$$p(y = j \mid x) = \frac{e^{s_j}}{\sum_k e^{s_k}}.$$

交叉熵损失：

$$L_i = -\log p(y_i \mid x_i) = -s_{y_i} + \log \sum_k e^{s_k}.$$

SVM 强调 margin；Softmax 强调概率校准和最大似然。

GoodNotes 任务：写出 $s = Wx + b$ ，画出一个三分类分数向量，分别用 SVM 和 Softmax 判断损失。

4 Optimization and Backpropagation

4.1 梯度下降

训练就是最小化损失：

$$\theta^* = \arg \min_{\theta} L(\theta).$$

梯度下降更新：

$$\theta_{t+1} = \theta_t - \eta \nabla_{\theta} L(\theta_t),$$

其中 η 是 learning rate。SGD 用小批量估计梯度：

$$\nabla_{\theta} L(\theta) \approx \frac{1}{B} \sum_{i \in \mathcal{B}} \nabla_{\theta} L_i(\theta).$$

4.2 链式法则

若

$$z = f(y), \quad y = g(x),$$

则

$$\frac{\partial z}{\partial x} = \frac{\partial z}{\partial y} \frac{\partial y}{\partial x}.$$

反向传播就是在计算图上反复使用链式法则，把最终 loss 的梯度传回每个参数。

4.3 反传的局部视角

每个节点只需要知道两件事：

- 前向：自己的输出；
- 反向：上游梯度乘本地导数。

例如乘法 $z = xy$ ：

$$\frac{\partial z}{\partial x} = y, \quad \frac{\partial z}{\partial y} = x.$$

ReLU：

$$\text{ReLU}(x) = \max(0, x), \quad \frac{\partial \text{ReLU}}{\partial x} = \begin{cases} 1, & x > 0, \\ 0, & x \leq 0. \end{cases}$$

GoodNotes 任务：画一个 $x \rightarrow y \rightarrow L$ 的计算图，标出前向值和反向梯度。

5 Neural Networks

5.1 从线性到非线性

线性分类器只能学习线性决策边界。多层网络堆叠 affine layer 和非线性激活：

$$h_1 = \text{ReLU}(W_1 x + b_1),$$

$$s = W_2 h_1 + b_2.$$

多层网络可表示更复杂的视觉模式，但也更难训练。

5.2 激活函数

Sigmoid:

$$\sigma(x) = \frac{1}{1 + e^{-x}}.$$

Tanh:

$$\tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}.$$

ReLU:

$$\text{ReLU}(x) = \max(0, x).$$

现代视觉网络常用 ReLU/GELU/SiLU 类激活，因为梯度传播更稳定。

5.3 初始化和正则化

若初始化太小，信号逐层消失；太大，激活爆炸。常见初始化让方差在层间近似保持稳定，例如 He initialization:

$$W_{ij} \sim \mathcal{N}\left(0, \frac{2}{n_{\text{in}}}\right).$$

正则化防止过拟合:

$$L_{\text{total}} = L_{\text{data}} + \lambda \|W\|_2^2.$$

6 Convolutional Neural Networks

6.1 卷积层

卷积利用图像的局部性和平移共享。若输入空间尺寸为 W ，卷积核尺寸为 F ，padding 为 P ，stride 为 S ，输出尺寸:

$$W_{\text{out}} = \frac{W - F + 2P}{S} + 1.$$

若卷积核数量为 K ，输入通道为 C ，参数量:

$$F \cdot F \cdot C \cdot K + K.$$

共享参数让 CNN 比全连接层更适合图像。

6.2 Pooling and Receptive Field

Pooling 汇聚局部响应，降低空间尺寸并增加局部不变性。感受野表示输出单元能看到输入图像的范围。层数越深，感受野越大，语义越抽象。

6.3 经典架构

- AlexNet: 证明深度 CNN 在 ImageNet 上有效。
- VGG: 使用堆叠 3×3 卷积，结构规整。
- GoogLeNet/Inception: 多尺度分支与 1×1 卷积降维。

- ResNet: 残差连接

$$y = F(x) + x$$

缓解深层网络优化困难。

GoodNotes 任务: 画一条 CNN 流水线: image $\rightarrow$ conv $\rightarrow$ ReLU $\rightarrow$ pool $\rightarrow$ classifier。

7 Training Tricks and Transfer Learning

7.1 Batch Normalization

BatchNorm 对 mini-batch 内的激活标准化:

$$\mu_B = \frac{1}{m} \sum_i x_i, \quad \sigma_B^2 = \frac{1}{m} \sum_i (x_i - \mu_B)^2,$$

$$\hat{x}_i = \frac{x_i - \mu_B}{\sqrt{\sigma_B^2 + \epsilon}}, \quad y_i = \gamma \hat{x}_i + \beta.$$

它改善优化稳定性, 也带来一定正则效果。

7.2 Dropout

训练时随机丢弃神经元:

$$m_i \sim \text{Bernoulli}(p), \quad \tilde{h}_i = \frac{m_i h_i}{p}.$$

这迫使网络不依赖单个特征。

7.3 Momentum and Adam

Momentum:

$$v_{t+1} = \mu v_t - \eta \nabla_{\theta} L(\theta_t), \quad \theta_{t+1} = \theta_t + v_{t+1}.$$

Adam 使用一阶矩和二阶矩估计:

$$m_t = \beta_1 m_{t-1} + (1 - \beta_1) g_t,$$

$$v_t = \beta_2 v_{t-1} + (1 - \beta_2) g_t^2.$$

7.4 Transfer Learning

若数据少, 直接从头训练大模型不现实。迁移学习流程:

pretrained backbone $\rightarrow$ freeze or finetune $\rightarrow$ task head.

对你的空间智能路线, ImageNet/CLIP/DINO/ViT backbone 可以作为检测、分割、深度、地图语义的表示层。

8 Detection and Segmentation

8.1 Detection

目标检测输出类别和边界框。框质量常用 IoU:

$$\text{IoU}(A, B) = \frac{|A \cap B|}{|A \cup B|}.$$

NMS 过滤重复框:

keep high score box, remove boxes with $\text{IoU} > \tau$.

Two-stage 检测器先提 proposals, 再分类和回归; one-stage 检测器直接密集预测。

8.2 Segmentation

语义分割给每个像素类别:

$$f_{\theta}(I)_{u,v} \rightarrow c.$$

实例分割还区分同类不同物体。对于空间智能, segmentation 是把图像转成可用于地图、规划和语言 grounding 的结构化表示。

8.3 Dense Prediction

深度估计、光流、分割都属于 dense prediction: 输出不是一个类别, 而是每个像素一个值或向量。典型结构是 encoder-decoder:

$$I \rightarrow z \rightarrow \hat{Y}.$$

9 RNN, Attention, and Transformers

9.1 RNN

序列模型维护隐藏状态:

$$\begin{aligned} h_t &= \phi(W_{xh}x_t + W_{hh}h_{t-1} + b_h), \\ y_t &= W_{hy}h_t + b_y. \end{aligned}$$

RNN 可用于图像描述、视频理解和时序状态建模, 但长序列训练困难。

9.2 LSTM

LSTM 用门控控制记忆:

$$\begin{aligned} f_t &= \sigma(W_f[h_{t-1}, x_t] + b_f), \\ i_t &= \sigma(W_i[h_{t-1}, x_t] + b_i), \\ o_t &= \sigma(W_o[h_{t-1}, x_t] + b_o), \\ c_t &= f_t \odot c_{t-1} + i_t \odot \tilde{c}_t. \end{aligned}$$

9.3 Attention

Scaled dot-product attention :

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right) V.$$

Transformer 把图像 patch 或 token 通过 self-attention 建模全局关系。ViT、DETR、CLIP、SAM 等现代视觉模型都来自这条线。

10 Generative Models

10.1 Autoencoder

Autoencoder 学习压缩表示：

$$z = f_{\theta}(x), \quad \hat{x} = g_{\phi}(z), \\ L = \|x - \hat{x}\|^2.$$

瓶颈 z 是对输入的低维表示。

10.2 VAE

VAE 学习概率潜变量：

$$q_{\phi}(z | x), \quad p_{\theta}(x | z).$$

优化 ELBO：

$$\mathcal{L} = \mathbb{E}_{q_{\phi}(z|x)}[\log p_{\theta}(x | z)] - D_{\text{KL}}(q_{\phi}(z | x) \| p(z)).$$

10.3 GAN

GAN 的 min-max 目标：

$$\min_G \max_D \mathbb{E}_{x \sim p_{\text{data}}}[\log D(x)] + \mathbb{E}_{z \sim p_z}[\log(1 - D(G(z)))].$$

生成模型让视觉从“识别世界”进一步走向“想象和生成世界”。

11 Self-supervised Vision

11.1 Contrastive Learning

对同一图像的不同增强视为正样本，对其他图像视为负样本。InfoNCE 形式：

$$\mathcal{L}_i = -\log \frac{\exp(\text{sim}(z_i, z_i^+)/\tau)}{\exp(\text{sim}(z_i, z_i^+)/\tau) + \sum_j \exp(\text{sim}(z_i, z_j^-)/\tau)}.$$

目标是让同一语义对象的表示靠近，不同对象远离。

11.2 Masked Modeling

Masked image modeling 随机遮挡 patch，让模型恢复缺失内容：

$$\hat{x}_{\mathcal{M}} = f_{\theta}(x_{\setminus \mathcal{M}}).$$

这与空间智能里的世界模型很接近：系统要从部分观测推断完整世界。

11.3 Vision-Language Representation

CLIP 类模型把图像和文本投到同一空间。图像表示 v 和文本表示 t 的相似度：

$$s(v, t) = \frac{v^T t}{\|v\| \|t\|}.$$

这条线是空间智能从 perception 走向 language-grounded planning 的桥。

12 CS231n 到空间智能的连接

CS231n 给你神经视觉 backbone，CS231A 给你 3D 几何约束。现代空间智能通常是：

image/video $\rightarrow$ visual features $\rightarrow$ geometry / depth / motion $\rightarrow$ world state $\rightarrow$ action.

学习顺序建议：

1. 用 CS231n 学会视觉表示：CNN、Transformer、self-supervised features。
2. 用 CS231A 学会几何：相机、对极、三角测量、SfM。
3. 用 SLAM/三维重建把表示和几何合并：feature matching、pose estimation、BA、dense map。
4. 用世界模型把视觉状态变成可预测、可决策的 latent state。

公式速查

kNN L2:	$d_2(x, x_i) = \sqrt{\sum_p (x_p - x_{i,p})^2}.$
Linear classifier:	$s = Wx + b.$
SVM:	$L_i = \sum_{j \neq y_i} \max(0, s_j - s_{y_i} + \Delta).$
Softmax:	$p(y = j \mid x) = \frac{e^{s_j}}{\sum_k e^{s_k}}.$
Cross entropy:	$L_i = -\log p(y_i \mid x_i).$
SGD:	$\theta_{t+1} = \theta_t - \eta \nabla_{\theta} L(\theta_t).$
ReLU:	$\text{ReLU}(x) = \max(0, x).$
Conv output:	$W_{\text{out}} = \frac{W - F + 2P}{S} + 1.$
BatchNorm:	$\hat{x}_i = \frac{x_i - \mu_B}{\sqrt{\sigma_B^2 + \epsilon}}.$
ResNet:	$y = F(x) + x.$
IoU:	$\text{IoU}(A, B) = \frac{ A \cap B }{ A \cup B }.$
Attention:	$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right) V.$
VAE ELBO:	$\mathcal{L} = \mathbb{E}_{q_{\phi}}[\log p_{\theta}(x \mid z)] - D_{\text{KL}}(q_{\phi}(z \mid x) \parallel p(z)).$
GAN:	$\min_G \max_D \mathbb{E}_x[\log D(x)] + \mathbb{E}_z[\log(1 - D(G(z)))].$

GoodNotes 页码建议

页码	标题	必画图
001	Image Classification	train/val/test 和 kNN 投票。
002	SVM and Softmax	分数向量、margin、概率。
003	Backprop	计算图和局部梯度。
004	Neural Network	affine-ReLU-affine 结构。
005	CNN	卷积核滑动、输出尺寸、参数量。
006	Training Tricks	BatchNorm、Dropout、Momentum。
007	Detection/Segmentation	box、IoU、mask。
008	Attention	Q, K, V 和 token 关系图。
009	Generative Models	encoder/decoder、VAE、GAN。
010	Spatial Bridge	CS231n feature 到 CS231A geometry 的连接图。